

TD법

한 걸음의 경험으로 갱신하기: 부트스트래핑, 그리고 정책이 갱신식에서 사라지는 자리

sajacaros
sajacall82@naver.com

2026년 9월 10일

초록

앞 장의 몬테카를로법(MC법)은 환경 모델을 버리고 표본 평균으로 가치를 얻었지만, 수익 G_t 의 정의에 에피소드 끝까지의 보상이 들어 있어 판이 끝나야 한 번 배울 수 있었다. TD법(Temporal Difference)은 기다리지 않는다. 아직 받지 못한 보상의 합을 지금 갖고 있는 추정치 $V(S_{t+1})$ 로 대신 놓고 한 걸음마다 갱신한다. 본고는 그 교체에서 출발하여 TD 정책 평가, 온-정책 제어인 SARSA, 중요도 샘플링으로 보정하는 오프-정책 SARSA, 그리고 Q 러닝을 정리하고, 네 알고리즘이 “다음 상태의 값을 누구에게서 받아 오는가”라는 하나의 축 위의 서로 다른 지점임을 보인다. 원서[1] 6장은 예제 코드를 제공하므로 본고는 그것을 그대로 쓰되, 원서가 관찰로만 남기거나 아예 짚지 않은 자리에 다섯 가지 논의를 더하였다. 절 구성은 원서 6장의 목차를 그대로 따르며, 더한 논의는 별도의 절로 떼지 않고 그것이 필요해지는 자리의 본문에 “[보충]”으로 표시해 두었다. 첫째, 원서가 표로만 적어 둔 “TD법은 편향이 있고 분산이 작다”를 같은 실험 안에서 두 양으로 갈라 측정하고, 두 방법의 우열이 에피소드 수에 따라 뒤집히는 지점을 보인다. 둘째, 원서가 그림 6-7의 아래 줄 화살표를 “SARSA가 안전한 길을 배운 것”으로 읽는 대목을 검산한다. ϵ -소프트 정책 가운데 가장 좋은 것을 정확히 계산하면 그 자리의 최선은 여전히 UP이고, 화살표가 왼쪽을 가리키는 진짜 원인은 $\alpha = 0.8$ 이다. 에피소드를 20 배로 늘려도 바뀌지 않지만 α 를 0.1로 낮추면 시드 20개 중 17개가 뒤집힌다. 셋째, 예제의 오프-정책 SARSA가 쓰는 목표 $\rho(R + \gamma Q')$ 가 교과서의 $R + \gamma \rho Q'$ 와 다르다는 것을 밝히고, 이 환경에서는 두 형태의 차이가 실측으로 나타나지 않는 까닭을 갱신 136,813회 가운데 23 회라는 숫자로 제시한다. 넷째, Q 러닝의 오차가 0.00으로 찍히는 것이 알고리즘이 아니라 환경 덕임을 보인다. 이 환경에서 Q 러닝의 TD 목표는 분산이 정확히 0이라 앞 장에서 본 고정값 α 의 잔차 띠가 사라지며, 전이에 미끄러짐을 넣으면 그 정확도도 함께 사라진다. 다섯째, 샘플 모델 판본이 1,000 에피소드에서 남기는 오차가 하필 1.0000인 까닭을 밝힌다.

주제어: 강화 학습, TD법, 부트스트래핑, TD 오차, SARSA, 오프-정책, 중요도 샘플링, Q 러닝, 벨만 최적 방정식, 분포 모델, 샘플 모델

차례

서론	2
6.1 TD법으로 정책 평가하기	3
6.1.1 TD법 도출	3
6.1.2 MC법과 TD법 비교	5
6.1.3 TD법 구현	6
6.2 SARSA	8
6.2.1 온-정책 SARSA	8
6.2.2 SARSA 구현	9

6.3	오프-정책 SARSA	12
6.3.1	오프-정책과 중요도 샘플링	12
6.3.2	오프-정책 SARSA 구현	12
6.4	Q 러닝	14
6.4.1	벨만 방정식과 SARSA	14
6.4.2	벨만 최적 방정식과 Q 러닝	15
6.4.3	Q 러닝 구현	15
6.5	분포 모델과 샘플 모델	17
6.5.1	분포 모델과 샘플 모델	17
6.5.2	샘플 모델 버전의 Q 러닝	18
6.6	정리	19
	재현 정보	19

서론

끝날 때까지 기다리지 않기

앞 장[2]에서 모델을 버리고 표본 평균으로 가치를 얻었다. 갱신식은

$$V(S_t) \leftarrow V(S_t) + \alpha \{ G_t - V(S_t) \} \quad (1)$$

이고, 여기에는 p 도 r 도 없다. 대신 다른 것이 들어 있다. G_t 는 t 부터 에피소드가 끝날 때까지 받은 보상을 전부 더한 값이므로, 이 한 줄을 실행하려면 판이 끝나야 한다.

값이 두 가지다. 판이 길면 갱신이 그만큼 드물어진다. 앞 장의 그리드 월드의 무작위 정책에서 한 에피소드가 평균 44.8걸음이었으니 45걸음을 걷고 갱신을 한 묶음 하는 셈이었다. 그리고 끝이 없는 지속적 과제에는 아예 쓸 수 없다. G_t 가 정의되지 않기 때문이다.

이 장은 G_t 를 기다리지 않는다. 앞 장에서 이미 쓴 재귀 구조 $G_t = R_t + \gamma G_{t+1}$ 을 다시 꺼내면, 모르는 것은 G_{t+1} 하나뿐이다. 그 자리에 지금 갖고 있는 추정치 $V(S_{t+1})$ 을 넣는다.

$$V(S_t) \leftarrow V(S_t) + \alpha \{ R_t + \gamma V(S_{t+1}) - V(S_t) \}. \quad (2)$$

R_t 와 S_{t+1} 은 한 걸음만 걸으면 알 수 있으므로 갱신이 걸음마다 일어난다. 아직 부정확한 추정치를 목표로 삼아 다른 추정치를 고치는 이 방식을 부트스트래핑이라 하며, 앞 장의 DP도 같은 성격이었다.

교체의 대가는 편향이다. G_t 는 참값 주위에 고르게 흩어지지만 $R_t + \gamma V(S_{t+1})$ 은 V 가 틀린 만큼 한쪽으로 치우친 값이다. 대신 얻는 것이 작은 분산과 잦은 갱신이며, 이 저울이 어느 쪽으로 기울는지를 §6.1 끝에서 실측한다.

정책이 갱신식에서 사라지는 자리

평가에 개선을 붙여 제어로 넘어가면 앞 장에서 만난 갈림길이 다시 나온다. 걷는 정책과 평가받는 정책을 같게 둘 것인가 다르게 둘 것인가. 앞 장의 답은 중요도 가중치 ρ 였고, 그 ρ 가 걸음마다 곱해 쌓이면서 분산이 커지는 것이 MC법 오프-정책의 약점이었다.

TD법에서는 한 걸음만 내다보므로 곱이 하나로 끝난다. 앞 장의 약점이 크게 줄어드는 것이 이 장의 첫 번째 소득이다. 두 번째 소득은 더 크다. 다음 상태의 값을 “실제로 고른 행동의 Q ” 대신 “ $\max_a Q$ ”로 바꾸면 정책이 갱신식에서 통째로 사라지고, 보정할 것이 없으니 ρ 도 필요 없어진다. 그 알고리즘이 Q 러닝이며, 3장에서 벨만 방정식과 벨만 최적 방정식을 가르던 $\sum_a \pi(a | s)$ 대 $\max_a$ 의 차이가 여기서 알고리즘의 차이로 나타난다.

본고의 구성과 기여

본고는 원서 6장의 목차를 그대로 따른다. §6.1에서 TD법을 도출해 정책 평가에 쓰고, §6.2에서 Q 로 바꾸어 온-정책 제어인 SARSA를 만든다. §6.3에서 걷는 정책과 평가받는 정책을 갈라 한 걸음분 ρ 로 보정하고, §6.4에서 그 ρ 마저 없애는 Q 러닝에 이른다. §6.5에서 정책을 확률분포로 들고 있을 필요가 없다는 것을 확인해 코드를 Q 하나로 줄인다. §6.6에서 정리한다.

원서 6장은 예제 코드를 제공하므로 본고는 그것을 그대로 쓰되, 원서가 관찰로만 남기거나 아예 짚지 않은 다섯 자리에 논의를 더하였다. 절을 따로 만들어 밀어 두지 않고, 그것이 필요해지는 자리의 본문에 “[보충]”으로 표시해 두었다.

1. **편향과 분산을 갈라 보기**(§6.1 끝). 원서는 MC법과 TD법의 성질을 표로 적으며 편향은 TD법에, 분산은 MC법에 있다고 말하지만 어느 쪽이 얼마인지는 적지 않는다. 시드 200개로 두 양을 따로 측정하고, 두 방법의 우열이 에피소드 수에 따라 뒤집히는 것을 보인다.
2. **그림 6-7의 화살표는 안전한 길이 아니다**(§6.2 끝). 원서는 SARSA가 고른 아래 줄의 왼쪽 화살표를 “ ε 만큼 헤매는 자기 자신을 평가하므로 폭탄을 피한 것”으로 읽는다. ε -소프트 정책 가운데 가치가 가장 높은 것을 정확히 계산하면 그 자리의 최선은 $\varepsilon = 0.5$ 까지도 UP이며, 화살표의 원인은 위험 회피가 아니라 $\alpha = 0.8$ 이다. 원인을 에피소드 수, α , 탐색 시작 셋으로 갈라 확인한다.
3. **ρ 를 곱하는 자리**(§6.3 끝). 예제의 목표 $\rho(R + \gamma Q')$ 는 보상 R 까지 함께 보정하는데, 교과서의 형태는 $R + \gamma \rho Q'$ 로 ρ 가 다음 상태의 값에만 붙는다. 두 형태를 같은 조건에서 돌려 견주고, 이 환경에서 차이가 드러나지 않는 까닭을 밝힌다.
4. **오차 0.00은 환경이 준 것**(§6.4 끝). 원서는 Q 러닝의 값이 앞 장 DP의 값과 정확히 일치하는 것을 이 장에서 가장 인상적인 결과로 제시한다. 이 환경에서 Q 러닝의 TD 목표는 분산이 정확히 0이라 앞 장 [보충]에서 본 폭 $\sqrt{\alpha/(2-\alpha)}\sigma$ 의 잔차 띠가 사라진다는 것을 보이고, 전이에 미끄러짐을 넣어 정확도가 함께 사라지는 것을 확인한다.
5. **하필 1.0000인 오차**(§6.5 끝). 원서 예제는 에피소드 수가 1,000 이라 학습이 덜 된 상태로 끝나는데, 남은 오차가 어중간한 값이 아니라 정확히 1.0000이다. 그 값이 어느 칸에서 오는지 밝힌다.

수렴 정리의 증명, $TD(\lambda)$ 와 적격 흔적, 최대화 편향과 이중 Q 러닝 같은 대목은 이 장의 줄거리를 따라가는 데 꼭 필요하지 않아 덜어냈다.

6.1 TD법으로 정책 평가하기

6.1.1 TD법 도출

앞의 두 장이 가치 함수를 구한 방식은 백업 다이어그램의 어디를 쓰느냐로 갈린다.

두 방법의 제약이 서로 다른 축에서 온다. DP의 제약은 폭에 있고 MC의 제약은 깊이에 있다. 그러면 폭도 한 줄기, 깊이도 한 층으로 두면 둘 다 피할 수 있다.

식으로 따라가면 출발점은 3장의 재귀 구조다.

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots = R_t + \gamma G_{t+1}. \quad (3)$$

가치 함수의 정의 $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$ 에 넣으면

$$v_\pi(s) = \mathbb{E}_\pi[R_t + \gamma G_{t+1} \mid S_t = s] = \mathbb{E}_\pi[R_t + \gamma v_\pi(S_{t+1}) \mid S_t = s] \quad (4)$$

가 된다. 두 번째 등호에서 G_{t+1} 이 $v_\pi(S_{t+1})$ 로 바뀐 것은 조건부 기댓값을 한 번 더 취한 것이며, 이 식이 3장의 벨만 방정식이다.

그림 6-1 DP법과 MC법 비교




그림 1. DP법(왼쪽)과 MC법(오른쪽)이 쓰는 범위. 왼쪽은 폭이 넓고 깊이가 한 층이다. 다음 상태를 빠짐없이 훑되 한 걸음만 내려가며, 전부 훑으려면 p 와 π 를 알아야 한다. 오른쪽은 폭이 한 줄기고 깊이가 끝까지다. 모델은 필요 없지만 바닥에 닿아야, 곧 에피소드가 끝나야 값이 나온다. 출처: 원서 그림 6-1.

그림 6-2 TD법 아이디어




그림 2. TD법이 쓰는 범위. 한 줄기만 겪으므로 모델이 필요 없고, 한 층에서 멈추므로 에피소드가 끝나기를 기다리지 않는다. 잘라 낸 아래쪽은 지금 갖고 있는 추정치 $V(S_{t+1})$ 로 대신한다. 출처: 원서 그림 6-2.

여기서 길이 같린다. 기댓값을 확률로 펼쳐 쓰면

$$v_{\pi}(s) = \sum_a \pi(a | s) \sum_{s'} p(s' | s, a) \{ r(s, a, s') + \gamma v_{\pi}(s') \} \quad (5)$$

이고, 등호를 갱신식으로 바꿔 읽은 것이 앞 장의 반복적 정책 평가였다. 우변에 π 와 p 가 그대로 남아 있어 모델을 알아야만 계산된다.

펼치지 않고 식 (4)의 기댓값 모양 그대로 두면 사정이 다르다. 우변에 p 도 π 도 없고 기댓값 기호만 남아 있으니, 앞 장에서 배운 대로 표본의 평균으로 근사할 수 있다. 표본 하나는 실제로 한 걸음 걸어서 얻은 $R_t + \gamma V(S_{t+1})$ 이다.

그림 6-3 MC법과 TD법 비교

$$\langle \text{MC법} \rangle \quad V'_{\pi}(S_t) = V_{\pi}(S_t) + \alpha \{ G_t - V_{\pi}(S_t) \}$$

$$\langle \text{TD법} \rangle \quad V'_{\pi}(S_t) = V_{\pi}(S_t) + \alpha \{ R_t + \gamma V_{\pi}(S_{t+1}) - V_{\pi}(S_t) \}$$

그림 3. 두 갱신식에서 다른 곳은 하늘색으로 칠한 자리 하나뿐이다. MC법은 실제로 받은 수익 G_t 를, TD법은 한 걸음 뒤에 곧바로 알 수 있는 $R_t + \gamma V(S_{t+1})$ 을 목표로 삼는다. 출처: 원서 그림 6-3.

$$\text{MC법: } V(S_t) \leftarrow V(S_t) + \alpha \{ G_t - V(S_t) \}, \quad (6)$$

$$\text{TD법: } V(S_t) \leftarrow V(S_t) + \alpha \{ \underbrace{R_t + \gamma V(S_{t+1})}_{\text{TD 목표}} - V(S_t) \}. \quad (7)$$

$R_t + \gamma V(S_{t+1})$ 을 TD 목표, 중괄호 전체 $R_t + \gamma V(S_{t+1}) - V(S_t)$ 를 TD 오차라 한다.

아직 부정확한 $V(S_{t+1})$ 을 목표로 삼아 $V(S_t)$ 를 고치는 것이 이상해 보이지만, 매 걸음 R_t 라는 실제로 받은 값이 조금씩 섞여 들어온다. 잘못된 추정치끼리 서로를 참조하는 것이 아니라 진짜 정보가 한 걸음씩 뒤로 스며드는 구조이며, 앞 장의 DP도 같은 방식으로 참값에 다가갔다.

6.1.2 MC법과 TD법 비교

두 목표값의 성질이 갈리는 곳은 흩어진 정도다.

G_t 에는 에피소드가 끝날 때까지 고른 행동과 겪은 전이의 무작위성이 전부 쌓인다. 앞 장에서 3×4 그리드 월드의 한 에피소드가 평균 44.8걸음이었으니 G_t 하나에 45번의 뽑기가 들어 있는 셈이다. TD 목표에 들어 있는 무작위성은 R_t 와 S_{t+1} , 곧 한 번의 뽑기뿐이다.

표 1. 두 목표값의 성질. 편향과 분산을 실제로 갈라 낸 것은 이 절 끝의 [보충]에 있다.

	MC법	TD법
목표값	G_t	$R_t + \gamma V(S_{t+1})$
언제 알 수 있나	에피소드가 끝난 뒤	한 걸음 뒤
편향	없음	있음(V 가 부정확한 만큼)
분산	큼(끝까지의 무작위성이 쌓임)	작음(한 걸음분)
지속적 과제	쓸 수 없음	쓸 수 있음

편향과 분산 가운데 무엇을 줄일지 고르는 저울이며, 갱신이 잦다는 점까지 더해 실무에서는 대체로 TD법이 앞선다.

그림 6-4 시간을 거듭할수록 '변동성'이 커진다.




그림 4. 같은 자리에서 출발한 자동차의 경로가 시간이 갈수록 부채꼴로 벌어진다. 왼쪽 점선까지의 결과는 폭이 좁고 오른쪽 점선까지 가면 크게 흩어진다. G_t 는 오른쪽 점선까지 간 값이고 $R_t + \gamma V(S_{t+1})$ 은 왼쪽 점선까지만 간 값이다. 출처: 원서 그림 6-4.

6.1.3 TD법 구현

```
def eval(self, state, reward, next_state, done):
    next_V = 0 if done else self.V[next_state] # 목표 지점의 가치는 0
    target = reward + self.gamma * next_V      # TD 목표
    self.V[state] += (target - self.V[state]) * self.alpha
```

코드 1. TD 정책 평가 (s01_td_eval.py), $\alpha = 0.01$

done일 때 next_v를 0으로 두는 것은 종료 상태 다음으로는 받을 보상이 없기 때문이다. 종료 상태의 가치는 정의상 0이다.

앞 장과 갈리는 자리는 갱신식이 아니라 호출 위치에 있다.

```
while True:
    action = agent.get_action(state)
    next_state, reward, done = env.step(action)

    agent.eval(state, reward, next_state, done) # 걸음마다 부른다
    if done:
        break
    state = next_state
```

코드 2. 실행 루프. agent.eval()이 if done 바깥에 있다

앞 장 ch05/s02_mc_eval.py에서는 같은 자리의 호출이 if done: 안에 있었다. 한 걸음 정보만으로 갱신이 끝나므로 memory도 사라졌다. 에피소드를 통째로 들고 있을 이유가 없어진 것이 TD법이 코드에 남기는 가장 눈에 띄는 흔적이다.

α 를 0.01로 작게 잡은 것은 갱신 횟수가 많기 때문이다. 한 에피소드에 한 번씩 갱신하던 앞 장과 달리 걸음마다 갱신하므로, 1,000 에피소드에서 갱신이 수만 번 일어난다. α 를 크게 잡으면 앞 장 [보충]에서 본 잔차 띠가 그만큼 넓어져 값이 출렁인다.

그림 6-5 TD법으로 얻은 가치 함수




그림 5. 1,000 에피소드를 돌린 뒤의 가치 함수. 앞 장 그림 5-12(MC법), 그 앞 장 그림 4-13(DP)과 거의 같은 그림이 나온다. 세 방법이 같은 정책을 평가하므로 답이 같아야 하고, 다른 것은 오차뿐이다. 출처: 원서 그림 6-5.

표 2. TD 정책 평가의 오차(무작위 정책, $\alpha = 0.01$, 시드 50개). 기준은 앞 장의 정확한 v_π 다. 같은 양을 MC법과 짝지어 견준 것은 이 절 끝의 [보충]에 있다.

지표	값
$\max_s V(s) - v_\pi(s) $ 의 평균	0.0855
$V(s)$ 의 RMSE	0.0376
$V(s) - v_\pi(s)$ 의 평균(부호 포함)	-0.0011

[보충] 편향과 분산을 갈라 보기

원서는 편향이 TD법에 있고 분산이 MC법에 있다고 적을 뿐 어느 쪽이 얼마인지는 적지 않는다. 두 양을 갈라 보려면 따로 뽑아야 한다. 같은 시드로 만든 궤적 하나를 세 갱신식에 똑같이 먹이고 시드 60개에서 상태별로 평균과 표준편차를 구했다. 평균이 참값에서 벗어난 만큼이 편향이고, 시드 사이의 표준편차가 분산 쪽이다.

표 3. 무작위 정책 평가에서 편향과 표준편차(시드 60개, 세 방법이 같은 궤적을 쓴다). 값은 모두 학습 대상 10칸에 대한 평균이며 기준은 정확한 v_π 다. 세 번째 열 묶음은 앞 장이 쓴 $1/n$ 평균으로, 비교를 위해 함께 돌렸다.

에피소드	TD $\alpha = 0.01$ (예제)			MC $\alpha = 0.01$			MC $1/n$ (앞 장)		
	RMSE	편향	표준편차	RMSE	편향	표준편차	RMSE	편향	표준편차
250	0.0955	0.0749	0.0282	0.0903	0.0154	0.0836	0.0484	0.0048	0.0425
500	0.0447	0.0216	0.0321	0.0944	0.0098	0.0872	0.0368	0.0031	0.0325
1,000	0.0358	0.0044	0.0295	0.0971	0.0073	0.0924	0.0229	0.0021	0.0204
2,000	0.0412	0.0047	0.0333	0.1012	0.0080	0.0948	0.0174	0.0030	0.0152
4,000	0.0384	0.0062	0.0304	0.0951	0.0150	0.0857	0.0128	0.0018	0.0113
8,000	0.0366	0.0045	0.0302	0.0980	0.0056	0.0894	0.0094	0.0007	0.0082

α 를 맞춰 놓고 견주면 원서의 표가 그대로 확인된다. 1,000 에피소드에서 TD법의 표준편차는 0.0295이고 MC법은 0.0924로 세 배가 넘게 벌어지며, RMSE도 0.0358 대 0.0971로 그 차이를 그대로 따라간다. TD 목표에는 한 걸음분의 무작위성만 들어 있고 G_t 에는 평균 44.8 걸음분이 쌓인다는 사실이 숫자로 나온 것이다.

편향은 초반에만 보인다. 250 에피소드에서 TD법의 편향이 0.0749로 MC법의 0.0154보다




그림 6. 왼쪽: 세 방법의 RMSE. 고정값 α 를 쓰는 두 방법은 일찍 바닥에 닿아 더 내려가지 않고 $1/n$ 평균만 계속 내려간다. 오른쪽: 같은 실험을 편향(실선)과 표준편차(점선)로 나눈 것. TD법의 파란 실선이 250 에피소드에서 가장 높은 자리에서 시작해 가파르게 떨어지는 것이 부트스트래핑의 편향이 걸히는 모습이고, 파란 점선이 주황 점선의 3분의 1 자리에 가로놓인 것이 분산의 차이이다. ch06/paper/fig_td.py에서 생성.

다섯 배 가까이 큰데, V 가 아직 초깃값 0 근처에 있어 TD 목표 $R_t + \gamma V(S_{t+1})$ 이 통째로 작게 나오기 때문이다. 1,000 에피소드에서 0.0044까지 떨어져 MC법과 같은 수준이 된다. 부트스트래핑의 편향은 V 가 채워지면서 스스로 걷힌다.

한 가지가 더 보인다. TD법의 RMSE가 1,000 에피소드부터 0.036 근처에서 더 내려가지 않는다. 앞 장 [보충]에서 본 고정값 α 의 잔차 띠이며, MC법도 $\alpha = 0.01$ 을 쓰면 0.098에서 똑같이 멈춘다. 반면 $1/n$ 평균은 8,000 에피소드까지 계속 내려가 0.0094에 이른다. 그래서 예제가 쓰는 설정끼리, 곧 TD법($\alpha = 0.01$)과 앞 장의 MC법($1/n$)을 그대로 건주면 1,000 에피소드에서 0.0358 대 0.0229로 MC법이 앞선다. TD법이 진 것이 아니라 고정값 α 가 $1/n$ 평균에 진 것이며, 앞 장에서 본 저울이 여기서도 같은 방향으로 기울다.

정리하면 원서가 표로 적은 두 성질은 둘 다 사실이지만 유효 기간이 다르다. 분산의 차이는 학습이 끝날 때까지 남고, 편향의 차이는 초반 몇백 에피소드에서만 보인다.

6.2 SARSA

6.2.1 온-정책 SARSA

평가에 개선을 붙이면 제어가 된다. 앞 장 5.4.1절에서 확인했듯 모델이 없으면 탐욕화에 쓸 수 있는 것은 $\arg \max_a Q(s, a)$ 뿐이므로, 평가의 대상도 V 가 아니라 Q 여야 한다. TD 갱신식의 V 를 Q 로 바꾸면 그대로 옮겨진다.

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \{ R_t + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \}. \quad (8)$$

개선 쪽은 앞 장과 같은 ϵ -탐욕 정책이다.

$$\pi(a | s) = \begin{cases} \frac{\epsilon}{|\mathcal{A}|} + 1 - \epsilon & a = \arg \max_{a'} Q(s, a'), \\ \frac{\epsilon}{|\mathcal{A}|} & \text{그 밖의 행동.} \end{cases} \quad (9)$$

SARSA는 식 (8)의 평가와 식 (9)의 개선을 걸음마다 번갈아 한다. 앞 장의 MC 제어가 에피소드 마다 번갈아 하던 것을 한 걸음 단위로 잘게 쪼갠 것이며, 앞 장에서 일반화된 정책 반복이라 부른 틀 안에서 더 극단으로 간 지점이다.

그림 6-6 시간 t 와 $t + 1$ 에서의 상태와 행동 전이




그림 7. 갱신에 필요한 것을 시간 순으로 늘어놓은 것. $S_t, A_t, R_t, S_{t+1}, A_{t+1}$ 다섯이며, 머리글자를 따서 SARSA라 부른다. 오른쪽 끝의 A_{t+1} 까지 정해져야 갱신할 수 있으므로 갱신이 한 걸음 늦게 일어난다. 출처: 원서 그림 6-6.

6.2.2 SARSA 구현

```
self.memory = deque(maxlen=2)          # 최근 두 걸음만 보관

def update(self, state, action, reward, done):
    self.memory.append((state, action, reward, done))
    if len(self.memory) < 2:            # 아직 A_{t+1}을 모른다
        return

    state, action, reward, done = self.memory[0]
    next_state, next_action, _, _ = self.memory[1]
    next_q = 0 if done else self.Q[next_state, next_action]

    target = reward + self.gamma * next_q          # 평가
    self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
    self.pi[state] = greedy_probs(self.Q, state, self.epsilon) # 개선
```

코드 3. SARSA (s02_sarsa.py), $\alpha = 0.8, \varepsilon = 0.1$

앞 장의 memory가 에피소드 전체를 담았던 것과 달리 여기서는 길이 2면 충분하다. deque(maxlen=2)는 새 데이터를 넣으면 가장 오래된 것을 자동으로 밀어낸다.

목표에 도달했을 때 agent.update(next_state, None, None, None)을 한 번 더 부르는 것도 길이 2라는 구조에서 나온다. 마지막 걸음은 memory에 하나만 들어 있어 갱신되지 못하므로, 더미를 밀어 넣어 마지막 (S, A)까지 갱신되게 한다. done=True라 next_q는 0이 된다.

표 4. SARSA를 시드 50개로 돌린 성적($\alpha = 0.8, \varepsilon = 0.1, 10,000$ 에피소드, 기준은 앞 장이 쓴 최적해). 앞 장의 온-정책 MC 제어가 같은 조건에서 9.20/10과 RMSE 0.1439 였다.

지표	값
최적 행동 일치(평균)	7.62/10
10칸 모두 맞힌 시드의 비율	0%
$\max_s \max_a Q(s, a) - v_*(s) $ 의 평균	0.5709
$\max_a Q(s, a)$ 의 RMSE	0.2475
$\max_a Q(s, a) - v_*(s)$ 의 평균(부호 포함)	-0.1409

앞 장의 MC 제어보다 나쁘다. 10칸을 모두 맞힌 시드가 하나도 없고 값의 오차도 두 배 가까이 크다. 한 걸음마다 갱신하니 더 나아야 할 것 같은데 그렇지 않다.

원인의 일부는 평가 대상에 있다. 앞 장에서 본 대로 온-정책 제어가 다가가는 값은 v_* 가 아니라 ε -탐욕 정책 자신의 가치이므로 v_* 보다 아래다. 그러나 그 몫은 $\varepsilon = 0.1$ 에서 평균 -0.0235였고, 여기서 관찰된 -0.1409의 6분의 1에 지나지 않는다. 나머지는 α 에서 온다.

[그림 6-7] SARSA로 얻은 결과




그림 8. 10,000 에피소드로 학습한 Q 함수(왼쪽)와 그것을 탐욕화한 정책(오른쪽). 원서는 아래 줄의 왼쪽 화살표 셋에 “폭탄에서 멀어지는 행동”이라 적어 두었다. 셋 가운데 오른쪽 끝 (2,3)의 LEFT는 최적 정책과 같지만 (2,1)과 (2,2)는 다르며, 그 두 칸이 왜 그렇게 되는지는 이 절 끝의 [보충]에서 다룬다. 출처: 원서 그림 6-7.

[보충] 그림 8의 화살표는 안전한 길이 아니다

원서는 그림 8 아래 줄의 왼쪽 화살표를 이렇게 읽는다. SARSA가 평가하는 것은 ϵ 만큼 헤매는 자기 자신이므로, 폭탄 옆을 지나는 길을 고르면 열 번에 한 번은 실수로 폭탄에 빠지고 그 손해가 Q 에 반영되어 안전하지만 돌아가는 길을 고른다는 설명이다.

설명이 맞다면 ϵ -탐욕 정책의 가치를 정확히 계산했을 때도 그 자리의 최선이 LEFT 여야 한다. SARSA가 수렴하는 대상은 ϵ -소프트 정책 가운데 가치가 가장 높은 것이므로, 앞 장의 정책 반복법을 ϵ -소프트 정책으로 제한해 돌리면 그 값을 표본 없이 얻을 수 있다.

표 5. ϵ -소프트 정책 가운데 가장 좋은 것이 각 칸에서 고르는 행동. 모두 정책 반복법을 수렴할 때까지 돌려 얻은 정확한 값이며 표본이 섞이지 않았다. 오른쪽 두 열은 문제의 칸 (2,2)에서 두 행동의 가치다.

ϵ	(2,1)	(2,2)	(1,2)	$q((2,2), \text{UP})$	$q((2,2), \text{LEFT})$
0 (순수 탐욕)	RIGHT	UP	UP	0.8100	0.6561
0.1 (예제 값)	RIGHT	UP	UP	0.7684	0.6077
0.3	RIGHT	UP	UP	0.6575	0.4877
0.5	RIGHT	UP	UP	0.4894	0.3282
0.7	LEFT	UP	UP	0.2288	0.1616
0.9	LEFT	LEFT	UP	-0.1664	-0.0471

예제가 쓰는 $\epsilon = 0.1$ 에서 (2,2)의 최선은 UP이고 LEFT보다 0.16 앞선다. ϵ 을 0.5까지 올려도 순서가 바뀌지 않는다. 위험 회피가 실제로 정책을 뒤집으려면 ϵ 이 0.9는 되어야 한다.

이 환경에서 위험이 작은 까닭은 폭탄의 처지에 있다. 폭탄 칸 (1,3)은 밟아도 에피소드가 끝나지 않고 목표 바로 아래에 있다. 실수로 들어가면 -1을 받지만 곧바로 위로 올라가 +1을 받으므로 손해가 $-1 + \gamma \cdot 1.0 = -0.1$ 에 그친다. 낭떠러지에서 떨어지면 출발점으로 돌아가는 교과서의 예제와 성질이 다르다.

그러면 화살표는 어디서 오는가. 원인을 하나씩 없애 보면 갈린다.

경험을 20배로 늘려도 2/20 그대로다. 표본이 모자란 것이 아니다. α 를 0.1로 낮추면 같은 10,000 에피소드에서 17/20로 뒤집히고, 거기에 에피소드를 늘리면 $\max_a Q(2,2)$ 가 목표값 0.7684에 다가가며 자기 목표 기준 RMSE가 0.2389에서 0.0464로 떨어진다. 범인은 $\alpha = 0.8$ 이다.

표 6. (2, 2)에서 UP을 고른 시드의 수(시드 20개). “자기 목표 기준 RMSE”는 v_* 가 아니라 표 5에 있는 ε -소프트 최적 가치를 기준으로 한 것이므로, SARSA가 자기가 수렴해야 할 곳에 얼마나 이르렀는지를 나타낸다.

설정	(2, 2)에서 UP	(2, 2) 방문	$\max_a Q(2, 2)$	자기 목표 기준 RMSE
기본(10,000 에피소드, $\alpha = 0.8$)	2/20	378	0.3514	0.2389
에피소드 20배(200,000)	2/20	5,134	0.3353	0.2203
$\alpha = 0.1$	17/20	6,089	0.6624	0.1777
$\alpha = 0.1 + 200,000$ 에피소드	17/20	42,287	0.7211	0.0464
시작 상태를 무작위로($\alpha = 0.8$)	11/20	3,249	0.6640	0.1323

앞 장 [보충]에서 고정값 α 가 추정치를 한 점에 모이지 못하고 폭 $\sqrt{\alpha/(2-\alpha)}\sigma$ 의 띠 안에 남긴다는 것을 보았다. $\alpha = 0.8$ 이면 계수가 $\sqrt{0.8/1.2} = 0.8165$ 로, 앞 장이 쓰던 $\alpha = 0.1$ 의 0.2294 보다 세 배 넘게 크다. 남은 것은 σ , 곧 TD 목표가 얼마나 흔들리는지다.

표 7. 수렴한 Q 에서 TD 목표의 표준편차. SARSA의 목표 $R_t + \gamma Q(S_{t+1}, A_{t+1})$ 에는 $A_{t+1} \sim \varepsilon$ -탐욕이라는 뽑기가 들어 있고, Q 러닝의 목표 $R_t + \gamma \max_a Q(S_{t+1}, a)$ 에는 뽑기가 없다. 환경의 전이가 결정적이라 R_t 와 S_{t+1} 은 (s, a) 가 정해지면 확정이다.

	SARSA	Q 러닝
(s, a) 40개에 대한 $\sigma_{\text{목표}}$ 평균	0.0580	0
그 최댓값	0.1708	0
$\alpha = 0.8$ 에서 예상되는 잔차 띠(평균)	0.0473	0

(2, 2)에서 UP을 골랐을 때의 $\sigma_{\text{목표}}$ 는 0.1470이므로 예상 띠는 $0.8165 \times 0.1470 = 0.1200$ 이다.




그림 9. 왼쪽: $Q((2, 2), \text{UP})$ 이 학습 중에 움직이는 모습을 시드 다섯 개씩 겹쳐 그린 것. 파란 선(Q 러닝)은 $q_* = 0.8100$ 에 붙은 뒤 떨어지지 않고, 주황 선(SARSA $\alpha = 0.8$)은 위아래로 1이 넘는 폭을 오간다. 초록 선($\alpha = 0.1$)은 느리지만 점선으로 표시한 자기 목표 0.7684를 향해 올라간다. 오른쪽: 10,000 에피소드 이후 그 값이 실제로 머무는 자리의 분포. Q 러닝은 0.8100 한 점에 못 박혀 막대가 하나뿐이다. ch06/paper/fig_td.py에서 생성.

10,000 에피소드 이후의 값을 모아 실제로 재 보면 표준편차가 0.2381로 예상보다 2배 가까이 넓다. 앞 장 [보충]에서도 추정값이 이론값의 1.5배 남짓으로 나왔는데, 이론이 표본들의 독립을 가정하는 데 비해 실제로는 목표값 자신이 학습 중에 계속 움직이기 때문이다. α 를 0.1로 낮추면 같은 값이 0.0691로 좁아지고, Q 러닝에서는 0.0000이다.

정리하면 그림 8의 왼쪽 화살표는 위험을 피한 결과가 아니라 $\alpha = 0.8$ 이 남긴 폭 0.2 남짓의 흔들림에 (2, 2)의 두 행동 차이 0.16이 묻혀 버린 결과다. 그리고 그 흔들림은 스스로를 키운다. 값이 낮게 찍힌 칸은 정책이 등을 돌리고, 등을 돌리면 덜 방문되며, 덜 방문되면 값이 그대로 남는다.

방문 횟수가 시작 칸 14,271 번 대 (2, 2) 378 번으로 38배 벌어지는 것이 그 고리의 결과다. α 를 낮추면 (2, 2) 방문이 6,089번으로 16배 늘어난다.

원서가 $\alpha = 0.8$ 을 고른 데는 이유가 있다. §6.4의 Q 러닝에서는 이 값이 문제를 일으키지 않으며, 오히려 빠른 학습에 도움이 된다. 같은 α 가 두 알고리즘에서 갈리는 까닭은 Q 러닝의 TD 목표에 분산이 없다는 데 있다.

6.3 오프-정책 SARSA

6.3.1 오프-정책과 중요도 샘플링

동기는 앞 장 5.5절과 같다. 탐색은 ϵ -탐욕 정책 b 에 맡기고 평가는 탐욕 정책 π 에 대해 하고 싶다. 그렇게 하면 표 5에서 본 ϵ 몫이 사라진다.

먼저 갱신식에서 확률이 개입하는 자리를 찾는다.

그림 6-8 SARSA 갱신식에 대응하는 백업 다이어그램




그림 10. SARSA 갱신식에서 뽑기가 일어나는 두 자리. $S_t \rightarrow R_t, S_{t+1}$ 은 환경의 $p(s' | s, a)$ 이고 바꿀 수 없다. $S_{t+1} \rightarrow A_{t+1}$ 은 정책이며, 데이터를 모은 것은 b 인데 평가하고 싶은 것은 π 라 어긋나는 자리가 여기다. 출처: 원서 그림 6-8.

환경 쪽 뽑기는 어느 정책을 쓰든 같으므로 보정할 것이 없다. 남는 것은 A_{t+1} 하나다. $A_{t+1} \sim \pi$ 로 뽑혔다면 지금까지의 온-정책 SARSA이고,

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \{ R_t + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \}, \quad A_{t+1} \sim \pi, \quad (10)$$

b 로 뽑혔다면 앞 장의 중요도 가중치로 보정한다.

$$\rho = \frac{\pi(A_{t+1} | S_{t+1})}{b(A_{t+1} | S_{t+1})}, \quad A_{t+1} \sim b. \quad (11)$$

ρ 가 한 걸음분이라는 것이 앞 장과 갈리는 결정적인 자리다. 앞 장의 MC법에서는 종료까지의 가중치를 전부 곱해 쌓아야 했고, 곱이 길어질수록 0으로 꺼지거나 폭발하는 것이 고질적인 약점이었다. TD법은 한 걸음만 내다보므로 곱이 하나로 끝난다. 곱이 길어지지 않는 덕에 TD법은 오프-정책과 잘 맞는다.

6.3.2 오프-정책 SARSA 구현

```
if done:
    next_q = 0
    rho = 1
else:
    next_q = self.Q[next_state, next_action]
```

```

rho = self.pi[next_state][next_action] / self.b[next_state][next_action]

target = rho * (reward + self.gamma * next_q)      # rho로 TD 목표 보정
self.Q[state, action] += (target - self.Q[state, action]) * self.alpha

self.pi[state] = greedy_probs(self.Q, state, 0)    # 대상 정책: 탐욕
self.b[state] = greedy_probs(self.Q, state, self.epsilon) # 행동 정책: eps-탐욕

```

코드 4. 오프-정책 SARSA (s03_sarsa_off_policy.py), $\alpha = 0.8$, $\varepsilon = 0.1$

rho가 *=가 아니라 매번 새로 계산된다는 점이 앞 장과 다르다. 앞 장의 update()에는 rho *= ...가 있었고 그 한 글자가 분산의 근원이었다.

그림 6-9 오프-정책 SARSA로 얻은 결과




그림 11. 오프-정책 SARSA의 결과. 그림 8와 견주면 폭탄 칸 (1,3)이 UP으로 목표를 향하고 Q 값도 전반적으로 크다. 평가 대상이 헤매지 않는 탐욕 정책이라 실수로 폭탄에 빠지는 몫을 셈하지 않기 때문이다. 출처: 원서 그림 6-9.

표 8. 온-정책과 오프-정책 SARSA를 시드 50개로 견준 것($\alpha = 0.8$, $\varepsilon = 0.1$, 10,000 에피소드).

	최적 행동	10/10	$\max_s \max_a Q - v_* $	RMSE
SARSA (s02)	7.62/10	0%	0.5709	0.2475
오프-정책 SARSA (s03)	8.36/10	22%	0.6199	0.2885

앞 장 5.5절에서 본 것과 같은 모양이 나온다. 정책은 더 잘 맞히고(7.62 → 8.36칸, 10칸을 모두 맞힌 시드 0% → 22%) 값은 더 못 맞힌다(RMSE 0.2475 → 0.2885). 평가 대상이 탐욕 정책으로 바뀌어 ε 몫이 사라지는 대신 ρ 가 목표를 혼돈다.

[보충] ρ 를 공급하는 자리

예제의 목표는 $\rho(R_t + \gamma Q')$ 로, 괄호 안에 보상 R_t 가 함께 들어가 있다. 교과서가 쓰는 형태는 다르다.

$$\text{예제: } \rho(R_t + \gamma Q(S_{t+1}, A_{t+1})), \quad \text{교과서[3]: } R_t + \gamma \rho Q(S_{t+1}, A_{t+1}). \quad (12)$$

ρ 가 보정하려는 것은 A_{t+1} 을 어느 정책으로 뽑았느냐이고, R_t 는 A_{t+1} 이 정해지기 전에 이미 받은 값이라 보정 대상이 아니다. 그래서 교과서 형태에서는 ρ 가 다음 상태의 값에만 붙는다. 예제 형태에서는 $\rho = 0$ 일 때 목표가 통째로 0이 되어 실제로 받은 보상까지 지워진다.

차이가 결과로 나타나는지 같은 조건에서 견주었다.

표 9. 두 목표 형태를 시드 50개로 견준 것. 갱신식의 나머지는 모두 같다.

목표	최적 행동	10/10	$\max_s \max_a Q - v_* $	RMSE
$\rho(R_t + \gamma Q')$ (예제)	8.36/10	22%	0.6199	0.2885
$R_t + \gamma \rho Q'$ (교과서)	8.46/10	22%	0.6270	0.2932

표 10. 한 걸음 가중치 ρ 가 실제로 취한 값(시드 0, 10,000 에피소드, 갱신 136,813회). 대상 정책이 결정적이고 행동 정책이 ε -탐욕이라 값이 사실상 넷뿐인 것은 앞 장 [보충]과 같다. 1.0은 아직 갱신되지 않아 두 정책이 모두 초기 균등분포인 칸이고, 40은 두 번의 greedy_probs() 호출이 동점을 다르게 푼 경우다.

ρ	횟수	비율	언제
1.081	117,234	85.69%	A_{t+1} 이 두 정책의 탐욕 행동일 때
1.0	10,014	7.32%	두 정책이 아직 균등분포일 때
0	9,564	6.99%	A_{t+1} 이 π 의 탐욕 행동이 아닐 때
40	1	0.00%	동점을 두 호출이 다르게 풀었을 때

차이가 시드 사이의 흔들림에 묻힌다. 까닭은 ρ 가 취하는 값의 분포에 있다.

$\rho = 0$ 이 되는 것은 갱신의 6.99%뿐이다. 앞 장 MC법에서 같은 값이 59.9%였던 것과 크게 다른데, 앞 장에서는 누적값이라 한 걸음만 어긋나도 그보다 앞선 걸음이 전부 죽었기 때문이다. 한 걸음짜리 ρ 가 0이 되려면 A_{t+1} 이 탐욕 행동이 아니어야 하고, ε -탐욕 정책에서 그 확률은 $\varepsilon \cdot 3/4 = 7.5\%$ 이고, 실측한 6.99%가 거기에 맞는다.

두 형태가 실제로 갈리는 것은 $\rho = 0$ 이면서 보상이 0이 아닌 갱신뿐인데, 그런 갱신이 136,813회 가운데 23회다. 이 환경은 보상이 목표 칸과 폭탄 칸에서만 나오고 나머지 10칸에서는 모두 0이라 두 형태가 만날 기회 자체가 드물다. 보상이 걸음마다 나오는 환경이라면 두 형태의 차이가 드러날 것이며, 그때는 교과서 형태를 써야 한다.

6.4 Q 러닝

오프-정책 SARSA는 여전히 ρ 를 들고 다닌다. 그것마저 없앨 수 있는지가 이 절의 질문이며, 답은 3장의 두 방정식에 있다.

그림 6-10 벨만 방정식과 SARSA, 벨만 최적 방정식과 Q 러닝의 관계

벨만 방정식 $\longrightarrow$ SARSA

벨만 최적 방정식 $\longrightarrow$ Q 러닝

그림 12. 이 절의 결론. 벨만 방정식을 표본으로 바꾸면 SARSA가 되고, 벨만 최적 방정식을 표본으로 바꾸면 Q 러닝이 된다. 3장에서 두 방정식을 가르던 것은 $\sum_a \pi(a | s)$ 와 $\max_a$ 의 차이 하나였다. 출처: 원서 그림 6-10.

6.4.1 벨만 방정식과 SARSA

벨만 방정식이 퍼뜨리는 두 갈래에서 각각 한 줄기씩 뽑은 것이 SARSA이며, 그래서 SARSA를 벨만 방정식의 표본 판본이라 부른다. 문제도 거기서 나온다. $\pi(a | s)$ 에서 뽑아야 하는데 실제로 걷는 것은 b 다. 오프-정책으로 만들려면 ρ 로 그 어긋남을 메워야 했다.

그림 6-11 Q 함수에서 벨만 방정식의 백업 다이어그램




그림 6-12 SARSA의 백업 다이어그램




그림 13. 왼쪽: Q 함수에 대한 벨만 방정식의 백업 다이어그램. 갈래가 두 번 퍼지며, 한 번은 $p(s' | s, a)$ 로 다른 한 번은 $\pi(a | s)$ 로 퍼진다. 정확히 계산하려면 두 갈래를 모두 훑어야 하므로 모델이 필요하다. 오른쪽: 두 갈래에서 각각 한 줄기씩 뽑은 것이 SARSA다. 출처: 원서 그림 6-11, 6-12.

6.4.2 벨만 최적 방정식과 Q 러닝

그림 6-13 Q 함수에서 벨만 최적 방정식의 백업 다이어그램




그림 6-14 샘플링 버전 벨만 최적 방정식의 백업 다이어그램




그림 14. 왼쪽: 벨만 최적 방정식의 백업 다이어그램. 마지막 층이 확률적 선택이 아니라 MAX 이고 회색으로 흐려진 가지는 버려진다. 오른쪽: 그것을 표본으로 바꾼 것. 뽑기 표시가 한 군데뿐이며, $\max_a Q(S_{t+1}, a)$ 는 이미 갖고 있는 Q 표를 훑어 얻으므로 뽑기가 아니다. 출처: 원서 그림 6-13, 6-14.

마지막 층에서 정책이 사라졌다는 것이 전부다. 식에 π 도 b 도 등장하지 않으니 어긋날 것이 없고, 어긋나지 않으니 보정할 것도 없다. ρ 가 필요 없어진다.

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \{ R_t + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \}. \quad (13)$$

SARSA의 식 (8)과 다른 곳은 $Q(S_{t+1}, A_{t+1})$ 이 $\max_a Q(S_{t+1}, a)$ 로 바뀐 자리 하나다.

A_{t+1} 을 기다릴 필요가 없어져 갱신이 한 걸음 안에서 끝나고, 코드에서 deque가 사라진다.

6.4.3 Q 러닝 구현

표 11. 다음 상태의 값을 어디서 받아 오는가. 세 알고리즘의 차이가 그 한 열에서 갈린다.

	다음 상태의 값	갱신에 필요한 것	성격
SARSA	실제로 고른 A_{t+1} 의 Q	A_{t+1}	온-정책
오프-정책 SARSA	같은 ρ 보정	A_{t+1}, π, b	오프-정책
Q 러닝	$\max_a Q(S_{t+1}, a)$	없음	오프-정책, 보정 불필요

```
def update(self, state, action, reward, next_state, done):
    if done:
        next_q_max = 0
    else:
        next_qs = [self.Q[next_state, a] for a in range(self.action_size)]
        next_q_max = max(next_qs) # SARSA와 다른 단 한 곳

    target = reward + self.gamma * next_q_max
    self.Q[state, action] += (target - self.Q[state, action]) * self.alpha

    self.pi[state] = greedy_probs(self.Q, state, epsilon=0) # 대상 정책
    self.b[state] = greedy_probs(self.Q, state, self.epsilon) # 행동 정책
```

코드 5. Q 러닝 (s04_q_learning.py), $\alpha = 0.8$, $\varepsilon = 0.1$

그림 6-15 Q 러닝으로 얻은 Q 함수와 정책




그림 15. Q 러닝의 결과. Q 값이 1.00, 0.90, 0.81, 0.73, 0.66처럼 γ 의 거듭제곱으로 정확히 찍히고, 폭탄으로 향하는 행동만 $-0.10 = -1 + \gamma \cdot 1.00$ 이다. 오른쪽 정책은 앞 장의 최적 정책과 같다. 출처: 원서 그림 6-15.

표 12. 이 장의 네 알고리즘을 같은 조건에서 견준 것($\varepsilon = 0.1$, 10,000 에피소드, 시드 50개). 위의 셋은 $\alpha = 0.8$ 이고 정책 평가만 $\alpha = 0.01$ 이라 따로 두었다.

	최적 행동	10/10	$\max_s \max_a Q - v_* $	RMSE
SARSA (s02)	7.62/10	0%	0.5709	0.2475
오프-정책 SARSA (s03)	8.36/10	22%	0.6199	0.2885
Q 러닝 (s04)	9.66/10	86%	0.0674	0.0245
Q 러닝, 샘플 모델 (s05, 10,000회)	9.84/10	84%	0.1132	0.0361

참고: 앞 장의 온-정책 MC 제어는 9.20/10, 48%, 0.3359, 0.1439였다.

차이가 크다. Q 러닝은 10칸을 모두 맞히는 시드가 86%이고 값의 RMSE가 SARSA의 10분의 1이다. 시드 50개 가운데 43개에서 $\max_a Q$ 가 앞 장 DP의 v_* 와 완전히 같았다. 모델을 보지 않고 걸어 다니기만 해서 얻은 값이 모델을 보고 계산한 값과 소수점 아래까지 일치하는 것이다.

두 가지를 짚어 둘 만하다. 최적 행동 일치가 9.66/10이고 10/10이 아닌 것은 대개 틀린 것이 아니라 동점이다. (2, 0)에서 UP과 RIGHT가 둘 다 0.6561이라 어느 쪽을 골라도 최적이며, 앞 장에서 이미 확인한 자리다. 그리고 수렴 대상이 다르다. SARSA가 다가가는 곳은 ϵ -소프트 최적 가치이지만 Q 러닝이 다가가는 곳은 q_* 자체다. 식 (13)이 벨만 최적 방정식의 표본 판본이기 때문이다.

[보충] 오차 0.00은 환경이 준 것

값이 정확히 맞는 것이 알고리즘의 일반적인 성질은 아니다. $\alpha = 0.8$ 이라는 큰 값을 쓰면서도 흔들리지 않는다는 사실 자체가 앞 장 [보충]과 어긋나 보인다. 고정값 α 는 추정치를 폭 $\sqrt{\alpha/(2-\alpha)}\sigma$ 의 띠 안에 남기고, $\alpha = 0.8$ 이면 그 계수가 0.8165였다.

빠진 것은 σ 다. Q 러닝의 TD 목표 $R_t + \gamma \max_a Q(S_{t+1}, a)$ 에서 R_t 와 S_{t+1} 은 이 환경이 결정적이라 (S_t, A_t) 가 정해지면 확정이고, $\max_a$ 에는 뽑기가 없다. 목표가 상수이므로 $\sigma = 0$ 이고, 띠의 폭도 $0.8165 \times 0 = 0$ 이다. 남는 것은 α 가 클수록 빠른 수렴뿐이라 $\alpha = 0.8$ 이 오히려 이득이 된다. 표 7의 두 열이 갈리는 자리가 바로 여기다.

설명이 맞다면 환경을 확률적으로 바꾸었을 때 정확도가 사라져야 한다. 고른 행동이 확률 미끄러짐으로 엉뚱한 행동으로 바뀌게 해 두고 같은 실험을 반복하였다.

표 13. 전이에 미끄러짐을 넣었을 때(시드 50개, 10,000 에피소드, $\alpha = 0.8$). “미끄러짐 10%”는 고른 행동이 10%의 확률로 네 행동 가운데 무작위로 바뀐다는 뜻이다. 기준 v_* 는 미끄러짐이 없는 환경의 값이라 미끄러짐을 넣은 두 줄의 오차에는 환경이 달라진 몫도 섞여 있다. 읽으려는 것은 오차의 크기가 아니라 정확히 0인 시드가 사라진다는 것이다.

환경	오차가 정확히 0인 시드	$\max_s \max_a Q - v_* $	최적 행동
결정적(원래 예제)	43/50	0.0674	9.66/10
미끄러짐 10%	0/50	0.5140	7.42/10
미끄러짐 30%	0/50	0.7320	7.08/10

미끄러짐을 10%만 넣어도 정확히 맞는 시드가 하나도 남지 않는다. 그리드 월드의 전이가 결정적이라는 성질이 준 결과이며, 확률적 환경에서 같은 정확도를 원하면 α 를 줄이거나 시간에 따라 줄여야 한다.

6.5 분포 모델과 샘플 모델

6.5.1 분포 모델과 샘플 모델

앞 장 5.1.2절에서 환경을 확률분포를 내주는 분포 모델과 표본만 내주는 샘플 모델로 갈랐다. 같은 구분을 정책에도 쓸 수 있다.

표 14. 정책을 어떻게 들고 있는가.

	무엇을 저장하나	코드
분포 모델	확률분포 자체	<code>self.pi[state] = {0: 0.025, 1: 0.925, ...}</code>
샘플 모델	행동을 뽑는 절차만	<code>if rand() < eps: 무작위 else: argmax</code>

`s04_q_learning.py`는 분포 모델이다. `pi`와 `b`를 딕셔너리로 들고 있고 갱신마다 `greedy_probs()`로 다시 채운다. 그런데 Q 러닝의 갱신식 $R_t + \gamma \max_a Q(S_{t+1}, a)$ 에는 π 도 b 도 나오지 않는다. b 가 쓰이는 곳은 행동을 고를 때뿐이고, 그 규칙은 ϵ -탐욕 그대로다. 확률분포를 저장할 이유가 없다.

분포를 들고 있는 것이 불리해지는 경우도 있다. 행동이 많으면 딕셔너리가 그만큼 커지고, 행동이 연속값이면 표로 적는 것 자체가 불가능하다.

6.5.2 샘플 모델 버전의 Q 러닝

```
class QLearningAgent:
    def __init__(self):
        self.gamma, self.alpha, self.epsilon = 0.9, 0.8, 0.1
        self.action_size = 4
        self.Q = defaultdict(lambda: 0)    # pi도 b도 없다

    def get_action(self, state):
        if np.random.rand() < self.epsilon:    # eps의 확률로 무작위
            return np.random.choice(self.action_size)
        qs = [self.Q[state, a] for a in range(self.action_size)]
        return np.argmax(qs)    # 나머지는 탐욕
```

코드 6. 샘플 모델 판본 (s05_q_learning_simple.py)

클래스가 들고 있는 것이 Q 하나로 줄었다. `greedy_probs()` 호출도 π 와 b 의 갱신도 사라졌고, `get_action()`은 1.4.2절의 밴디트 에이전트와 거의 같은 모양이 되었다. 알고리즘은 바뀌지 않았고 표현만 바뀌었다.

표 12에서 두 판본의 성적이 사실상 같게 나온다. 이 형태가 다음 장부터 신경망으로 넘어갈 때의 출발점이 된다. 신경망은 Q 만 근사하면 되고 정책은 규칙으로 두면 되기 때문이다.

[보충] 하필 1.0000인 오차

예제 파일은 에피소드 수가 1,000이라 s04의 10,000보다 적고, 그만큼 학습이 덜 된 상태로 끝난다. 남는 오차가 눈에 띄는 것은 크기가 아니라 값이다.

표 15. 샘플 모델 판본을 에피소드 수만 바꾸어 돌린 것(시드 50개). “한 번도 방문되지 않은 칸”은 10,000번의 걸음 동안 그 칸에 한 번도 서 보지 못한 시드의 수다.

	1,000 에피소드	10,000 에피소드
$\max_s \max_a Q - v_* $ 의 평균	0.8485	0.1132
그 값이 정확히 1.0000인 시드	24/50	0/50
오차가 가장 큰 칸이 (1, 3)인 시드	25/50	2/50
오차가 가장 큰 칸이 (2, 3)인 시드	23/50	48/50
(1, 3)을 한 번도 방문하지 않은 시드	24/50	0/50
(2, 3)을 한 번도 방문하지 않은 시드	41/50	0/50

1.0000이라는 값은 $v_*(1, 3) = 1.0000$ 에서 그대로 온다. (1, 3)은 폭탄 칸이고 목표 바로 아래에 있어 한 걸음이면 +1을 받으므로 최적 가치가 정확히 1이다. 그 칸에 한 번도 서 보지 못하면 $Q((1, 3), \cdot)$ 이 초깃값 0에 그대로 남고, 오차가 $1.0000 - 0 = 1.0000$ 으로 찍힌다. 정확히 1.0000인 시드가 24개, (1, 3)을 한 번도 밟지 않은 시드가 24개로 수가 같다.

같은 사정으로 0.7290도 나온다. (2, 3)을 방문하지 않으면 오차가 $v_*(2, 3) = 0.7290$ 이 된다. 1,000 에피소드에서 41/50 시드가 그 칸을 밟지 못한다. 두 칸이 목표에서 가장 먼 구석이고 탐욕 정책이 지나갈 이유가 없어서다.

오차가 어중간한 소수가 아니라 참값과 딱 떨어지게 나오면 학습이 부정확한 것이 아니라 아예 시작되지 않은 칸이 있다는 신호다. 알고리즘의 문제가 아니라 경험이 닿지 않은 곳의 문제이며, 에피소드를 10,000으로 늘리면 방문하지 않은 칸이 사라지고 그런 오차도 함께 사라진다.

6.6 정리

이 장이 바꾼 것은 목표값 하나다. 앞 장이 에피소드가 끝나야 알 수 있는 G_t 를 목표로 삼았다면, 이 장은 한 걸음 뒤에 알 수 있는 $R_t + \gamma V(S_{t+1})$ 을 목표로 삼는다. 아직 부정확한 추정치를 목표에 끌어 쓰는 것이 부트스트래핑이고, 앞 장의 DP도 같은 성격이었다. 이 장의 TD법은 DP의 그 성질과 MC법의 “모델 없이 겪은 것에서 배운다”를 한자리에 놓은 것이다.

바뀐 자리를 따라 나머지가 정해졌다.

- **에피소드를 들고 있을 이유가 없어진다.** 한 걸음 정보로 갱신이 끝나므로 memory가 사라지고, 갱신 호출이 `if done` 바깥으로 나온다. 끝이 없는 지속적 과제에도 쓸 수 있게 된다.
- **편향이 생기고 분산이 줄어든다.** G_t 는 참값 주위에 고르게 흩어지지만 TD 목표는 V 가 틀린 만큼 치우친다. 대신 한 걸음분의 무작위성만 담아 폭이 좁다.
- **제어에는 Q 가 필요하다.** 앞 장과 같은 이유이며, V 를 Q 로 바꾸고 ε -탐욕 개선을 걸음마다 붙인 것이 SARSA다. 갱신에 $S_t, A_t, R_t, S_{t+1}, A_{t+1}$ 다섯이 필요해 `deque(maxlen=2)`가 등장한다.
- **오프-정책의 ρ 가 한 걸음분으로 줄어든다.** 앞 장에서는 종료까지의 가중치를 곱해 쌓아야 했고 그 곱이 분산의 근원이었다. 한 걸음만 내다보므로 곱이 하나로 끝난다.
- **$\max_a$ 로 바꾸면 정책이 식에서 사라진다.** 어긋날 것이 없으니 보정할 것도 없고, ρ 없이 오프-정책이 된다. 벨만 최적 방정식의 표본 판본이므로 수렴 대상이 q_* 자체다.
- **정책을 확률분포로 들고 있을 필요가 없다.** Q 러닝의 갱신식에 정책이 없으므로 뽑는 절차만 남기면 클래스가 Q 하나로 줄어든다.

네 알고리즘의 차이가 “다음 상태의 값을 누구에게서 받아 오는가” 한 열에 모인다.

표 16. 이 장의 네 알고리즘. 성적은 모두 같은 조건(10,000 에피소드, 시드 50개, $\varepsilon = 0.1$, $\alpha = 0.8$)에서 이 장이 측정한 것이며, 정책 평가는 제어가 아니라 성적을 적지 않았다.

	목표값	수렴 대상	$\max_a Q$ 의 RMSE
TD 정책 평가	$R_t + \gamma V(S_{t+1})$	v_π	—
SARSA	$R_t + \gamma Q(S_{t+1}, A_{t+1})$	ε -소프트 최적 가치	0.2475
오프-정책 SARSA	$\rho(R_t + \gamma Q(S_{t+1}, A_{t+1}))$	탐욕 정책의 q	0.2885
Q 러닝	$R_t + \gamma \max_a Q(S_{t+1}, a)$	q_*	0.0245

Q 러닝이 앞선 것은 두 가지가 겹친 결과다. 수렴 대상이 ε 에 물들지 않은 q_* 라는 점이 하나이고, 이 환경이 결정적이라 TD 목표의 분산이 0이어서 $\alpha = 0.8$ 이라는 큰 값이 흔들림 없이 빠른 수렴만 낳는다는 점이 다른 하나다. 뒤의 것은 알고리즘이 아니라 환경이 준 것이므로, 미끄러짐을 10%만 넣어도 정확히 맞는 시드가 사라진다.

여기까지의 한계는 Q 를 표로 들고 있다는 데 있다. 12칸짜리 그리드 월드라 딕셔너리 하나로 충분했지만, 상태가 연속값이거나 수억 개라면 표를 만들 수 없다. 다음 장부터는 그 표를 신경망으로 대신한다. 표현이 바뀌어도 갱신식은 이 장의 식 (13) 그대로이며, 바뀌는 것은 $Q(S_t, A_t)$ 를 어떻게 저장하고 어떻게 고치느냐다.

재현 정보

본고의 수치는 세 갈래에서 나왔다.

정확한 값(표 5, 표 7, 그리고 v_* 와 v_π)은 표본을 쓰지 않고 계산한 것이다. 그리드 월드의 가치 함수는 앞 장들의 반복적 정책 평가와 가치 반복법을 갱신 폭이 10^{-14} 아래로 떨어질 때까지 돌려 얻었고, ε -소프트 최적 정책은 정책 반복법을 ε -소프트 정책으로 제한해 돌린 것이다. TD 목표의 표준편차는 그렇게 얻은 Q 에서 A_{t+1} 에 대한 분산을 직접 계산했다.

예제 코드의 실측(표 2, 표 4, 표 6, 표 8, 표 9, 표 10, 표 12, 표 13, 표 15, 표 16)은 ch06/의 예제를 그대로 돌리고 계측만 덧붙인 것이다. 시드는 `np.random.seed()`에 0부터 차례로 넣었고, 항목 대부분이 50개다. 원인을 갈라 보는 표 6에는 에피소드를 200,000까지 늘리는 설정이 있어 계산 시간 때문에 시드가 20개이고, 방문 분포와 칸별 오차도 같은 이유로 20개다. ρ 의 분포는 시드 0 하나를 계측한 것이다.

그림 스크립트의 실측(표 3, 그림 6, 그림 9)은 ch06/paper/fig_td.py로 생성한다. 에피소드를 수십만 번 돌려야 해서 환경의 전이를 미리 표로 펼친 빠른 판본을 쓰지만 갱신식과 정책은 예제와 같다. 두 판본이 어긋나지 않는다는 것은 같은 양을 양쪽에서 재어 확인할 수 있다. 1,000 에피소드 TD 평가의 RMSE가 예제 코드에서 0.0376(시드 50개), 빠른 판본에서 0.0358(시드 60개)로 시드 사이의 흔들림 안에서 맞는다.

표 13의 미끄러짐은 예제를 고친 것이 아니라 환경 쪽에 덧붙인 것이다. 에이전트가 고른 행동을 그대로 `env.step()`에 넘기지 않고, 정해진 확률로 네 행동 가운데 하나를 새로 뽑아 넘긴다. 갱신식에 들어가는 `action`은 에이전트가 고른 쪽이다.

시드를 바꾸면 값이 달라지는 항목과 그렇지 않은 항목을 섞지 않았다. 표에 “평균”이라 적힌 것은 시드에 따라 흔들리는 값이다.

참고문헌

- [1] 사이토 고키, 밑바닥부터 시작하는 딥러닝 4: 파이썬으로 구현하는 강화 학습 알고리즘, 한빛 미디어, 2023.
- [2] sajacaros, 몬테카를로법: 기댓값을 표본 평균으로 바꾸기, 2026.
- [3] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [4] R. S. Sutton, “Learning to Predict by the Methods of Temporal Differences,” *Machine Learning*, vol. 3, pp. 9–44, 1988.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] G. A. Rummery and M. Niranjan, *On-line Q-learning Using Connectionist Systems*, Technical Report CUED/F-INFENG/TR 166, Cambridge University Engineering Department, 1994.

본 문서에 실린 그림 중 “원서 그림”으로 표기한 것은 참고문헌 [1]의 도판이며, 학습 정리 목적으로 인용하였다. 그 밖의 그림과 표는 본고에서 직접 생성한 것이다.